

RAPPORT DE PROJET TABLEAU DE BORD 2025

Evolution de la recherche et de la prise en charge des troubles du neurodéveloppement



Membres du groupe:

- KLEINHANS Emeline
- KONTA Gaoussou

Encadrants:

- MOKADEM Riad
- GHALBI Mohamed
- DERA KHSHANNIA Marzieh

TABLE DES MATIÈRES

TABLE DES FIGURES.....	3
HISTORIQUE DES MODIFICATIONS	4
REMERCIEMENTS	5
1. But, objet et domaine d'application	6
A) But du document.....	6
B) Présentation du sujet	6
C) Domaine d'application	7
D) Présentation du document.....	7
2. Documents et terminologie	8
A) Documents applicables.....	8
B) Documents de référence.....	8
Documents et liens de référence	8
Documentation des librairies utilisées.....	8
C) Terminologie.....	9
3. Gestion du projet	11
A) Ressources humaines	11
B) Ressources matérielles et logiciels utilisés	11
C) Organisation	12
4. Méthodologie et démarche de développement.....	14
A) Collecte de données	14
B) Préparation et nettoyage de données	17
C) Administration de données	20
D) Visualisation et valorisation de données	22
6. Gestion de configuration.....	23
Table des fichiers, charte de codage et versions	23
7. Contrôle et assurance qualité	24
8. Bilans et conclusion	25
Annexes.....	26

TABLE DES FIGURES

Figure 1 - Les Troubles Neuro Développementaux selon de DSM-V.....	7
Figure 2 - Diagramme de Gantt prévisionnel et réel	13
Figure 3 - Équation de recherche	15
Figure 4 - Processus d'Extraction d'Articles.....	16
Figure 5 - Étape du Web Scraping.....	16
Figure 6 - Traitement des colonnes Auteurs et Affiliations	17
Figure 7 - Processus de récupération et standardisation des pays.....	19
Figure 8 - Schéma conceptuel de notre base de données	21
Figure 9 - Schéma logique de notre base de données	21
Figure 10 – pages d’analyse géographique et démographique.....	23
Figure 11 – Pages Trouble et suje.....	24

HISTORIQUE DES MODIFICATIONS

Version	Objet de la modification	Date	Auteur(s)	Relecteur(s)
V0	Création du document	25/01/2025	Emeline	-
V1	Ajout structure du document	10/02/2025	Emeline	Gaoussou
V2	Début rédaction partie 1	13/02/2025	Emeline	Gaoussou
V3	Début rédaction 4.A)	19/02/2025	Emeline	
V4	Fin rédaction partie 1 et début partie 2	27/02/2025	Emeline	
V5	Suite rédaction partie 4	10/03/2025	Emeline	Gaoussou
V6	Rédaction partie 3	14/03/2025	Emeline	Gaoussou
V7	Rédaction 4.A) et 4.B) et début partie 4.C)	15/03/2025	Emeline	Gaoussou
VF	Toutes le reste	18/03/25	Gaoussou	Gaoussou

REMERCIEMENTS

Tout d'abord, nous tenons à remercier la Faculté Science et Ingénierie de l'Université Paul Sabatier de nous permettre de suivre cette formation et tout particulièrement Mr Riad Mokadem pour l'organisation et l'encadrement de ce projet tableau de bord dans le cadre de notre première année de master. Nous remercions également Mme Marzieh Derakhshannia pour son aide durant les séances de TP, ainsi que Mr Mohamed Ghalbi pour ces cours qui nous ont permis de réaliser ce projet avec de bonnes bases en modélisation, scrapping et visualisation de données.

Nous tenons aussi à adresser nos remerciements à Mr Gilles Hubert pour son cours de Data Warehouse et à Mr José Moreno pour son cours d'introduction à la fouille de textes et de réseaux, qui nous ont été très utiles pour la réalisation de ce projet. Sans oublier tous les enseignants qui nous ont accompagnés durant l'évolution de notre cursus, appris la programmation, les bases de données etc, ils nous ont donc transmis les bases nécessaires pour travailler sur ce type de projet, nous en sommes sincèrement reconnaissants.

1. But, objet et domaine d'application

A) But du document

Dans le cadre de la première année du master Science de Ingénierie des Données, il nous a été proposé de réaliser un projet tableau de bord afin de mettre en pratique différentes compétences acquises au cours de notre formation. L'objectif de ce projet est de développer un système d'aide à la décision élaboré à partir d'analyses détaillées sur des points d'intérêts. Ces dernières seront réalisées grâce à une visualisation de données textuelles issues d'un moteur de recherche de données bibliographiques spécialisé.

Le présent document constitue alors le rapport de ce travail qui a été réalisé en binôme, du 22 janvier au 18 mars, dans un contexte Client-Fournisseur. En effet, le cadre formel proposé est celui où les enseignants jouent le rôle du client et les étudiants celui du fournisseur.

B) Présentation du sujet

La première étape de ce projet tableau de bord a été de choisir le sujet que nous allions traiter. Notons que notre travail devait se baser sur un grand nombre d'articles scientifiques portant sur un sujet d'actualité, cela a donc constitué un critère de choix important. Après discussion avec le groupe et les enseignants, nous avons opté pour la proposition qui semblait la moins large afin de pouvoir plus facilement cibler nos axes d'analyse.

Nous avons alors choisi d'étudier l'**évolution de la recherche et de la prise en charge des troubles du neurodéveloppement**. En effet, ce sujet est non seulement de plus en plus étudié par les scientifiques, mais il est aussi et surtout un sujet qui concerne une part non négligeable de la population (1 personne sur 6).

Pour rappel, les Troubles du NeuroDéveloppement (TND) sont un ensemble de troubles cognitifs qui apparaissent durant la période du développement et qui sont caractérisés par des particularités de fonctionnement d'une ou plusieurs zones du cerveau impliquant la socialisation, la communication, le geste, l'attention, le

raisonnement, la mémoire ou encore les apprentissages. Cet ensemble de troubles comprend notamment le trouble du déficit de l'attention avec ou sans hyperactivité (TDAH), le trouble du spectre de l'autisme (TSA), les troubles de la communication, les troubles moteurs, les troubles spécifiques des apprentissages et les troubles du développement intellectuel.

Notons que la classification des TNDs a régulièrement évolué au cours du temps. Nous nous baserons ici sur la dernière version du manuel diagnostique et statistique des troubles mentaux (DSM-V en anglais), qui est un ouvrage de référence publié par l'association américaine de psychiatrie (AAP).




Figure 1 - Les Troubles Neuro Développementaux selon de DSM-V

C) Domaine d'application

Maintenant que notre sujet est présenté, nous précisons rapidement notre domaine d'application. Il découle naturellement que nous travaillerons autour du secteur de la santé et en l'occurrence de la santé mentale. Etant donné que notre sujet est à la croisée de la recherche et de la prise en charge, nous essayerons d'analyser nos résultats tant sur le penchant théorique que sur le versant pratique.

D) Présentation du document

Comme expliqué précédemment, ce document a pour but de rendre compte du travail réalisé pour ce projet tableau de bord. Pour ce faire, nous allons dans un

premier temps préciser le contexte dans lequel nous avons évolué, en présentant les différents documents sur lesquels nous nous sommes basés, ainsi que la terminologie employée. Par la suite, nous décrirons notre gestion du projet, notre démarche de développement et notre méthodologie. Enfin, nous exposerons dans une dernière partie notre bilan et nos conclusions.

2. Documents et terminologie

A) Documents applicables

Afin de mener à bien ce projet tableau de bord, nous nous sommes basés sur le cahier des charges fourni par notre client. Ce dernier constitue le document fondamental de ce projet puisqu'il contient notamment les objectifs, l'organisation et les livrables demandés. Le cahier des charges est par ailleurs le pilier central du cadre formel de type Client-Fournisseur dans lequel nous évoluons.

B) Documents de référence

Documents et liens de référence

Par la suite, nous avons dû effectuer des recherches pour étayer notre réflexion autour de ce sujet. Nous avons d'une part regroupé des documents de référence sur la thématique des TNDs, et d'autre part rassemblé les cours dont nous avons besoin pour mener à bien ce projet tableau de bord et notamment ses aspects techniques.

- Documents de référence sur les TNDs:

[Diagnostic and Statistical Manual of Mental Disorders : Fifth Edition Text Revision DSM-5-TR™](#)

- Documents de référence sur la partie technique:

Cours "*Bases de données*" de L Flex par M. Mojahid, S. Yin

Cours "*Data Warehouse*" de M1 par G. Hubert

Cours "*Projet tableau de bord*" de M1 par R. Mokadem, M. Ghalbi

Cours "*Introduction à la fouille de textes et de réseaux*" de M1 par J. Moreno

Documentation des librairies utilisées

Concernant la partie programmation en elle même, nous avons utilisé le langage de programmation Python et avons eu recours à différentes librairies afin de réaliser des tâches spécifiques, tant pour la partie scrapping que pour la partie nettoyage. Voici ci-dessous la liste des librairies utilisées, avec une description concise ainsi qu'un lien vers leur documentation.

- Pour la partie web scrapping:

requests: fonctions pour traiter les requêtes et réponses HTTP

[requests · PyPI](#)

BeautifulSoup: fonctions pour scraper des pages web

[beautifulsoup4 · PyPI](#)

csv: fonctions pour lire et écrire des données tabulaires en format csv

[csv — CSV File Reading and Writing — Python 3.13.2 documentation](#)

- Pour la partie nettoyage de données:

os: fonctions dépendantes du système d'exploitation

[os — Miscellaneous operating system interfaces — Python 3.13.2 documentation](#)

io: fonctions pour traiter divers types d'entrées sorties

[io — Core tools for working with streams — Python 3.13.2 documentation](#)

pandas: fonctions pour manipuler et analyser des données

[pandas documentation — pandas 2.2.3 documentation](#)

C) Terminologie

Pour plus de clarté, nous allons détailler dans cette sous-partie les différents termes ou acronymes utilisés dans ce rapport.

- **AAP**: Association Américaine de Psychiatrie
- **API**: Application Programming Interface
- **CSV**: Comma-Separated Values
- **DSM**: Diagnostic and Statistical Manual of Mental Disorders
- **HTTP**: HyperText Transfer Protocol

- **HTML**: HyperText Markup Language
- **PMID**: PubMed IDentifier
- **TDH**: Trouble du Déficit de l'Attention avec ou sans Hyperactivité (ADHD en anglais)
- **TF-IDF**: Term Frequency-Inverse Document Frequency
- **TND**: Trouble du NeuroDéveloppement
- **TSA**: Trouble du Spectre de l'Autisme (ADS en anglais)
- **UNIX**: famille de systèmes d'exploitation ouverts
- **URL**: Uniform Resource Locator

3. Gestion du projet

A) Ressources humaines

Dans le cadre de ce projet tableau de bord, il nous a été demandé de respecter une certaine organisation concernant la répartition des rôles et notamment de définir les responsables des différents pôles. Néanmoins, étant donné que nous avons réalisé ce projet en binôme, une organisation plutôt horizontale s'est naturellement mise en place. En effet, il n'y a pas eu de réel chef de projet puisque notre travail s'est basé sur des discussions et échanges directs entre les deux membres du groupe. Cependant, nous avons quand même procédé à une répartition des pôles pour un travail plus efficace. Gaoussou Konta s'est chargé d'être le responsable de gestion de configuration en s'occupant de gérer l'évolution du système et sa description technique. Emeline Kleinhans s'est chargée d'être la responsable de la rédaction du rapport en veillant à rassembler et mettre en forme les différentes informations permettant de rendre compte de notre travail. Toutefois, le pôle assurance et contrôle qualité s'est partagé de façon équitable entre nous deux, via des relectures mutuelles régulières.

B) Ressources matérielles et logiciels utilisés

Afin de mener à bien ce projet tableau de bord, nous avons eu besoin de différentes ressources. Sur l'aspect matériel, nous avons simplement utilisé nos ordinateurs personnels ou ceux des salles de TP. Mais sur l'aspect logiciels nous avons eu recours à des dispositifs plus spécifiques que nous présentons ci-dessous :

- **Python:**



Nous avons effectué l'ensemble de nos programmes avec le langage de programmation Python, tant pour le scraping que pour le nettoyage et la préparation des données.

- **Google Colab:**



Afin de pouvoir collaborer rapidement et facilement sur nos différents codes Python, nous avons utilisé Google Colab. En effet, cela nous a permis de partager des Notebook interactifs où nous avons pu écrire et décrire nos programmes.

- **Google Drive:**



Nous avons par ailleurs utilisé Google Drive afin d'avoir un espace partagé où mettre nos différents supports de travail (rapport, fichiers, csv, notebook etc).

- **Oracle:**



Afin de stocker, gérer et récupérer de grandes quantités de données, nous avons utilisé le système de gestion de base de données Oracle via un compte mis à notre disposition par l'université.

- **SQL Developer:**



Par ailleurs, nous avons utilisé SQL Developer, une interface graphique d'Oracle, afin de faciliter nos tâches sur la base de données. C'est notamment via ce logiciel que nous l'avons alimenté.

- **Power BI:**



Enfin, nous avons utilisé le logiciel Power BI pour réaliser notre tableau de bord permettant de visualiser nos données. Il permet par ailleurs d'accéder directement à notre source de données via une connexion Oracle.

C) Organisation

Une partie non négligeable de la gestion de projet est sans aucun doute la planification. En effet, il est important d'organiser les différentes tâches à faire dès le début d'un projet afin de pouvoir le livrer au client dans le temps imparti. Pour ce faire, nous avons réalisé un diagramme de Gantt sur lequel nous avons mentionné notre programme prévisionnel (en orange sur la figure ci-dessous) et notre programme réel (en rose sur la figure ci-dessous) pour les différentes phases de notre projet.

DIAGRAMME DE GANTT

Projet tableau de bord - M1 SID 2025
Gaoussou Maouloud Konta et Emeline Kleinhans




Figure 2 - Diagramme de Gantt prévisionnel et réel

Néanmoins, nous pouvons constater une nette différence entre la théorie et la pratique. En effet, nous n'avons malheureusement pas réussi à nous tenir au programme prévisionnel car la partie collecte et préparation des données à pris beaucoup plus de temps que ce que nous avons anticipé. Nous avons dû faire face à de nombreux défis tout au long de ce processus, tant sur l'équation de recherche, l'extraction, que le nettoyage. Nous détaillerons nos réflexions et choix dans les parties suivantes de ce rapport.

4. Méthodologie et démarche de développement

A) Collecte de données

Dans un premier temps, nous avons donc réfléchi à la façon dont nous allions collecter les données nécessaires à notre analyse. Etant donné que notre sujet est en lien direct avec la sphère de la santé, nous nous sommes naturellement tournés vers PubMed, le principal moteur de recherche de données bibliographiques pour le domaine de la biologie et de la médecine.



Ensuite, il nous a fallu réfléchir à l'**équation de recherche** qui allait nous permettre d'obtenir les articles qui nous intéressent. Cette dernière sera constituée de deux parties, l'une pour l'aspect troubles du neurodéveloppement (TND) et l'autre pour l'aspect recherche et prise en charge. Notons que l'ensemble de nos recherches s'effectueront en anglais, puisque c'est la langue la plus largement utilisée pour rédiger les articles scientifiques. Après avoir fait quelques recherches et avoir observé les mots clés qui semblaient revenir fréquemment, nous avons choisi de conserver pour la seconde partie de l'équation de recherche les termes *studies*, *meta-analysis*, *impact*, *evolution*, *assessment* et *factors*. Enfin, le choix des mots ou termes utilisés pour la première partie de l'équation fut plus complexe, de part la problématique inhérente à la classification des TNDs.

Pour plus de précision et de clarté concernant nos choix, nous allons alors faire une petite parenthèse historique. En effet, la classification des TNDs est en constante évolution, le terme lui-même n'est d'ailleurs apparu dans une classification officielle qu'à partir de 2013 (dans le DSM-V). Afin de couvrir une période plus large pour avoir une meilleure idée des évolutions que nous souhaitons étudier, nous avons donc élargi notre recherche jusqu'à 1994 (date de parution du DSM-IV). Il y a certes eu des changements d'appellation et de description des différents troubles, mais nous avons fait tout notre possible pour les rassembler par catégorie.

Une fois toutes ces considérations prises en compte, il a été choisi de faire un compromis entre une équation de recherche basée sur la dernière classification de l'AAP (ne permettant pas d'accéder aux articles utilisant les termes employés avant celle-ci) et une équation de recherche plus exhaustive (trop longue et complexe pour l'échelle de notre projet). Par ailleurs, nous avons essayé de veiller à ce que les termes utilisés ne fassent pas appel, ou du moins le moins possible, à des troubles développés à la suite d'un accident ou d'une autre condition. C'est donc à la suite de ce raisonnement que nous avons obtenu l'équation de recherche suivante:

(“neurodevelopmental disorders” OR “learning disorders” OR “dyslexia” OR
 “dyscalculia” OR “attention deficit hyperactivity disorder” OR “autism” OR
 “asperger” OR “intellectual developmental disorder” OR “intellectual
 disability” OR “mental retardation” OR (“communication disorders” AND
 “neurodevelopmental disorders”) OR (“motor disorders” AND
 “neurodevelopmental disorders”) OR “developmental coordination disorder”
 OR “dyspraxia”)

AND

(“studies” OR “meta-analysis” OR “diagnostic” OR “diagnosis” OR “therapy”
 OR “treatment” OR “interventions” OR “factors” OR “assessment” OR
 “comorbidity” OR “management” OR “impact” OR “evolution”)

Figure 3 - Équation de recherche

Nous avons appliqué cette équation de recherche de 1994 (date de parution du DSM-IV) à 2024 et en cochant le filtre “full text”. Nous avons également ajouté lors de notre requête l’étiquette *[tiab]* après chaque mot ou expression libre afin que ces derniers soient recherchés uniquement sur les champs libres (c’est-à-dire dans le titre, l’abstract et les mots-clés, et non dans les articles similaires ou ceux qui ont cité l’article en question). Notons que les *[tiab]* ont été enlevé de l’encadré ci-dessus pour une meilleure lisibilité.

Une fois notre équation de recherche établie nous avons obtenu 92 762 résultats sur Pubmed, et donc autant d’articles à parcourir pour collecter nos données. Pour ce faire, nous avons alors fait appel au **web scraping**, une technique permettant d’extraire automatiquement des données depuis des sites web. En effet, pour pouvoir procéder à l’administration et à la visualisation des données, nous avons dû convertir les ressources présentes sur le web HTML en un format structuré. Notons qu’une API, nommée E-utilities, commune à PubMed et d’autres sites spécialisés existe et s’utilise via des lignes de commande UNIX. Néanmoins, par gain de temps, nous avons préféré réaliser un programme Python pour l’extraction de données. C’est en effet le langage de programmation que nous maîtrisons le mieux et nous avons pu nous appuyer sur un exemple concret de web scraping donné en cours.

Plus concrètement, pour effectuer notre web scraping, nous avons créé un notebook sur Google Colab, nommé *Code_scraping_projet_tableau_de_bord.ipynb*, constitué de huit parties. Nous allons donc les expliquer une à une ci-dessous:

1/ importation des librairies nécessaires (*requests* pour traiter les requêtes et réponses HTTP, *BeautifulSoup* pour le web scraping, *csv* pour lire et écrire des données tabulaires en format csv et *files* de google colab pour pouvoir télécharger le fichier csv obtenu)

2/ définition de la fonction *scrape_pubmed_article* qui prend en paramètre un PMID (identifiant d’un article de PubMed) et retourne un dictionnaire contenant l’identifiant de

l'article, son titre, son abstract en anglais, ses mots clés (keywords), ses auteurs, leurs affiliations et le date de publication de l'article

3/ définition de la fonction `scrape_pubmed_search_results` qui prend en paramètre un lien URL et le nombre maximal de pages à parcourir puis retourne une liste contenant le descriptif (obtenu grâce à la `fonction précédente`) de l'ensemble des articles visités

4/ définition de la fonction `save_to_csv` qui prend en paramètre la liste contenant le descriptif des articles ciblés (obtenue grâce à la `fonction précédente`) et le nom du fichier CSV que l'on veut obtenir puis retourne le fichier en question

5/ déclarer la variable `base_search_url` en lui affectant le lien URL correspondant à celui obtenu sur PubMed avec notre équation de recherche

6/ déclarer la variable `max_pages` (nombre maximal de pages à parcourir déduit de notre recherche sur PubMed) et affecter à la variable `articles` le résultat de la fonction `scrape_pubmed_search_results` ayant pour paramètres `base_search_url` et `max_pages`

7/ faire appel à la fonction `save_to_csv` pour sauvegarder les résultats obtenus à l'étape précédente

8/ télécharger ce fichier sur notre ordinateur grâce à une fonction de google colab




Figure 4 - Processus d'Extraction d'Articles

Grâce au programme préalablement décrit, nous pouvons donc collecter, sauvegarder et télécharger les informations qui nous intéressent à partir d'un lien URL PubMed correspondant à notre équation de recherche. Néanmoins, sur un tel nombre d'articles, cela prend beaucoup de temps. Par ailleurs, nous sommes également soumis à la contrainte de ne pas dépasser 10 000 articles par exécution, sinon nous sommes bloqués par le site. C'est donc pour ces deux raisons que nous avons choisi de scinder notre scraping en différentes périodes de temps afin de procéder par blocs inférieurs à 10 000 articles, en l'occurrence: 1994-2004, 2005-2008, 2009-2011, 2012-2013, 2014-2015, 2016, 2017, 2018, 2019-2020,

2021, 2022, 2023 et 2024. Une fois ces fichiers obtenus, nous avons donc dû les rassembler en un seul fichier *pubmed_results_all.csv* grâce à un code Python contenu au début de notre fichier *Code_nettoyage_projet_tableau_de_bord.ipynb*. Ce dernier permet donc de parcourir notre dossier Google Drive contenant nos différents fichiers csv, de les convertir en DataFrame puis de les rassembler grâce à la fonction *concat* de la librairie pandas.

Figure 5 - Étape du Web Scraping



B) Préparation et nettoyage de données

Une fois le fichier *pubmed_results_all.csv* obtenu, nous avons dû procéder à la préparation et au nettoyage des données afin d'obtenir un jeu de données plus facilement exploitable. Pour ce faire, nous avons réalisé différentes étapes réparties dans deux notebook différents, l'un nommé *Code_nettoyage_projet_tableau_de_bord.ipynb* pour l'exécution de la partie nettoyage et l'autre pour

la partie transformation nommé *Code_transformation_projet_tableau_de_bord.ipynb*.

Pour la partie **nettoyage**, nous avons choisi d'effectuer les traitements suivants:

- suppression de la deuxième partie inutile de la date (ex: pour conserver uniquement "2025 Jan" dans "2025 Jan;62(1):962-972"), puis convertir la date en un format uniforme grâce à la fonction *to_datetime* de pandas
- suppression des "[" et "]" lorsqu'il y en a dans le titre
- suppression des doublons, préalablement identifiés grâce aux PMID
- mettre tout le contenu des colonnes *Keywords*, *Titre*, *Abstract* et *Affiliations* en minuscules afin de faciliter le futur traitement de texte
- suppression des articles qui n'ont pas l'abstract
- lorsque les mots clés ne sont pas disponibles, remplacer les "[" par "NaN" et lorsqu'il y en a, suppression des caractères spéciaux inutiles

Ensuite, une partie **transformation** s'est imposée, notamment par la grande proportion d'articles pour lesquels il n'y avait pas de mots clés (environ 43%). Pour ce faire, nous avons commencé par essayer d'appliquer la méthode TF-IDF sur les abstracts mais cela

nous donnait des mots distincts alors que dans notre contexte nous avions plutôt besoin d'expressions (ex: avoir "autism spectrum disorder" au lieu de "spectrum" et "disorder"). Pour essayer de résoudre ce problème, nous avons alors créé une liste d'expressions recherchées à partir des Keywords mentionnés pour les articles qui en ont, afin de la mettre comme paramètre *vocabulary* lors de l'appel de la fonction *TfidfVectorizer*. Cela semblait mieux fonctionner mais ces deux essais n'ont pas pu aboutir à cause du temps de traitement considérable (ex: 3h n'ont pas suffi à analyser les articles de 2024). Devant cette situation, nous avons donc dû trouver une autre solution afin d'avoir tout de même, en un temps raisonnable, le type de trouble traité par l'article, ainsi que le sujet qu'il aborde. Le notebook *Code_transformation_projet_tableau_de_bord.ipynb* permet donc de créer ces deux nouvelles colonnes:

- *TypeTrouble* qui contient le ou les types de trouble traités par l'article, ces derniers étant trouvés en comparant un dictionnaire *TNDs* aux mots présents dans le titre (ou si besoin ceux présents dans les mots clés ou sinon ceux présents dans l'abstract). Notons que le dictionnaire en question a été créé par nos soins en associant à chaque clé ou type de trouble, une liste de mots ou expressions associées (en incluant des formulations différentes et/ou des sous types de trouble). Voici ci-dessous le dictionnaire ainsi créé:

```
{'neurodevelopmental disorders': ['neurodevelopmental disorders',
'Neurodevelopmental Disorder'],
'specific learning disorder': ['learning disorders', 'dyslexia',
'dyscalculia'],
'attention deficit hyperactivity disorder': ['attention deficit
hyperactivity disorder', 'ADHD', 'Attention-Deficit/Hyperactivity
Disorder', 'attention-deficit hyperactivity disorder'],
'autism spectrum disorders': ['autism', 'autism spectrum disorder',
'autism spectrum disorders', 'asperger', 'ASD', 'autistic'],
'intellectual developmental disorder': ['intellectual developmental
disorder', 'intellectual disability', 'intellectual disabilities',
'mental retardation'],
'communication disorder': ['communication disorders'],
'motor disorders': ['motor disorders', 'developmental coordination
disorder', 'dyspraxia', 'tic disorders', 'Tourette syndrome',
'stereotypic movement disorder']}
```

- *TypeSujet* qui contient le ou les thématiques abordées par l'article, trouvées en comparant une liste *sujets* aux mots présents dans l'abstract. Notons que cette liste a été constituée à partir de la deuxième partie de notre équation de recherche. La voici ci-dessous:

```
['studies', 'meta-analysis', 'diagnostic', 'diagnosis', 'therapy',
'treatment', 'interventions', 'factors', 'assessment', 'comorbidity',
'management', 'impact', 'evolution']
```


Notons que pour ces deux colonnes, il y a tout de même des cas où la cellule n'a pas pu être remplie (424 pour *TypeTrouble* et 1873 pour *TypeSujet*). Nous avons alors décidé de supprimer les articles correspondants.

Pour cette partie, l'objectif principal est de structurer et de standardiser les informations des auteurs afin de faciliter l'analyse et l'exploitation des données. Sachant que la structure de base pour lier auteur et affiliation est la suivante : si auteur 1 est affilié à affiliation 1 dans nos CSV bruts, obtenus par scraping, nous avons pour chaque article une colonne "auteurs" avec le format "nom,1" et une colonne "affiliation" avec le format "1,description,pays". Ce n'est pas toujours le cas pour les affiliations, mais cette manière est majoritaire.

- `authors_dict` est la colonne `authors_dict` regroupe les auteurs, leurs affiliations, leurs pays, leur continent, et leur niveau de développement. Pour ce faire, nous avons utilisé les bibliothèques `re` pour les expressions régulières, `uuid` pour générer des identifiants uniques, et `pandas` pour manipuler les DataFrames. Ces outils sont essentiels pour traiter et organiser les données brutes.

Ensuite, la fonction `create_authors_dict` associe les affiliations aux auteurs en découpant les chaînes de texte et en extrayant les informations pertinentes. Chaque auteur est associé à un identifiant unique, un nom, une affiliation, et un pays. Le pays est extrait de l'affiliation et standardisé pour des noms courants comme "United States" ou "United Kingdom".

Ensuite, la fonction `create_authors_dict` associe les affiliations aux auteurs en découpant les chaînes de texte et en extrayant les informations pertinentes. Chaque auteur est associé à un identifiant unique, un nom, une affiliation, et un pays. Le pays est extrait de l'affiliation et standardisé pour des noms courants comme "United States" ou "United Kingdom".



La fonction `test_affiliation_extraction` vérifie le bon fonctionnement du découpage des affiliations. La fonction `process_row` est appliquée à chaque ligne du DataFrame pour créer une nouvelle colonne `auteur_dict` contenant les dictionnaires d'auteurs, tout en gérant les valeurs manquantes ou non valides.

Figure 6 - Traitement des colonnes Auteurs et Affiliations

Pour ajouter les pays dans notre colonne `authors_dict`, nous avons compilé une liste de noms de pays et de variantes courantes afin d'identifier les pays mentionnés dans les affiliations.

Des expressions régulières sont utilisées pour nettoyer les données et extraire les informations pertinentes, en éliminant les adresses e-mail, les numéros de téléphone, et autres éléments non pertinents.

Correction des Pays : La fonction `corriger_pays` standardise les noms de pays en prenant en compte les abréviations, les variantes, et les faux positifs potentiels. Par exemple, "USA", "U.S.", et "United States" sont tous convertis en "United States". La fonction gère également les cas où les affiliations contiennent des abréviations d'états américains ou des institutions spécifiques, en s'assurant qu'elles ne sont pas confondues avec des pays.

Mise à Jour du DataFrame : Les pays non standardisés dans le DataFrame sont remplacés par leurs équivalents corrects, garantissant ainsi que toutes les analyses ultérieures reposent sur des données cohérentes et fiables.




Figure 7 - Processus de recuperation et standardisation des pays

C) Administration de données

Maintenant que les données sont collectées, nettoyées et préparées, il nous faut désormais procéder à l'administration de données afin de pouvoir les visualiser par la suite. Pour ce faire, nous avons donc conçu une base de données, décrite ci-dessous par son schéma conceptuel (réalisé sur MOCODO) et son schéma logique.




Figure 8 - Schéma conceptuel de notre base de données

```

ARTICLE(pmid, titre, date)
AUTEUR(id_auteur, nom, affiliation,
pays,continent, developpement)
TROUBLE(id_trouble, type)
SUJET(id_sujet, mot)
REDIGER(#pmid, #id_auteur)
TRAITER(#pmid, #id_trouble)
ABORDER(#pmid, #id_sujet)
  
```

Figure 9 - Schéma logique de notre base de données

Nous avons décidé d'alimenter notre base de données sur SQL Developer via des fichiers csv préalablement préparés avec Python. Il y a donc autant de fichiers csv que de tables décrites dans notre schéma logique.

D) Visualisation et valorisation de données

Enfin, la dernière étape de notre développement étant la visualisation et la valorisation de données, dans ce partie on va décrire la conception et l'implémentation d'une base de données SQLite pour l'analyse bibliométrique d'articles scientifiques sur divers troubles médicaux et psychologiques. La base de données, connectée à Power BI via ODBC, permet d'étudier les tendances de recherche, les collaborations internationales, et les disparités géographiques.



Les tables principales incluent des informations sur les auteurs, articles, troubles, et sujets, avec des relations many-to-many pour modéliser les co-écritures et les thématiques abordées.

Power BI facilite l'analyse visuelle et interactive, offrant des visualisations clés comme l'évolution temporelle des publications et la distribution géographique de la recherche. L'architecture est portable, performante, et extensible, avec des

perspectives d'amélioration incluant l'intégration de citations et l'automatisation des mises à jour.

Le tableau de bord analyse 83 000 articles sur des troubles médicaux et psychologiques, l'outil offre aux chercheurs, aux institutions académiques une interface interactive pour explorer les tendances de recherche. Il combine une base de données SQLite robuste et des mesures DAX pour des calculs précis et une visualisation dynamique.

La force du tableau de bord réside dans l'association d'une base de données robuste (configurée dans une base SQLite relationnelle) et de mesures DAX pointues, garantissant des calculs précis et une visualisation dynamique des indicateurs clés.

La page d'analyse géographique et démographique ci-dessous permet d'explorer les données scientifiques par localisation. Les utilisateurs peuvent filtrer par pays continent pou années pour comparer l'activité de recherche. Des statistiques agrégées, comme 13 000 articles et 54 000 auteurs, quantifient les contributions scientifiques.

Une carte mondiale interactive montre les pays contributeurs, mettant en lumière les hubs de recherche et les zones moins représentées. Cette visualisation aide à identifier les pays leaders et ceux nécessitant plus de soutien. Des graphiques complémentaires, comme les barres horizontales pour la distribution des articles par sujet et les graphiques circulaires pour

la répartition des auteurs par mots-clés, enrichissent l'analyse. Un filtre basé sur le niveau de développement économique permet d'évaluer l'impact du contexte socio-économique sur la production scientifique, facilitant ainsi des ajustements stratégiques pour soutenir la recherche. Ces fonctionnalités offrent une lecture multi-dimensionnelle de l'activité scientifique mondiale, aidant à identifier les tendances régionales et à comparer les pays de manière claire et intuitive.




Figure 10 – pages d'analyse géographique et démographique

La page trouble et sujet du tableau de bord se concentre sur l'analyse des troubles et des sujets de recherche, offrant une vue détaillée de l'évolution des publications scientifiques. Les utilisateurs peuvent interagir avec des filtres dynamiques pour sélectionner parmi sept types de troubles (comme l'ADHD ou l'autisme) et des sujets spécifiques (tels que l'évaluation ou le diagnostic). Cette approche permet une analyse granulaire et ciblée des données.

Des graphiques temporels dynamiques montrent l'évolution du nombre d'articles de 1990 à 2020, révélant les périodes de pics d'intérêt scientifique et l'émergence de nouveaux sujets. Un graphique en treemap illustre la répartition des auteurs par continent, mettant en lumière les contributions majeures de l'Europe, de l'Asie et de l'Amérique du Nord.

Un menu de navigation interactif facilite l'accès aux informations, permettant aux utilisateurs de basculer entre les onglets "Article" et "Trouble et sujet". Cette interface intuitive, combinée à des visualisations dynamiques, offre une exploration approfondie sans surcharge cognitive. La page permet ainsi d'identifier rapidement les tendances de recherche et d'orienter les futures investigations ou décisions de financement.




Figure 11 – Pages Trouble et sujet

Le tableau de bord a été conçu dans une approche collaborative, où chaque acteur joue un rôle clé. Le fournisseur a créé une base de données SQLite robuste avec une structure relationnelle optimisée, assurant la qualité et la cohérence des données. Il a également développé des mesures DAX performantes pour extraire des indicateurs pertinents et conçu une interface utilisateur ergonomique avec des filtres interactifs et des visualisations intuitives.

Le client bénéficie d'un outil clé en main, accessible sans compétences techniques approfondies. Il peut explorer l'évolution temporelle des recherches, détecter des synergies ou disparités entre disciplines, et évaluer la contribution des auteurs selon leur géolocalisation. Cette transparence permet aux utilisateurs de générer des insights stratégiques, d'identifier des opportunités de collaboration, et de prendre des décisions éclairées, qu'il s'agisse d'orienter des politiques de financement, de planifier de nouvelles études ou d'établir des partenariats internationaux.

8. Bilans et conclusion

Le projet d'analyse bibliométrique des troubles médicaux et psychologiques a été une initiative ambitieuse, combinant des aspects techniques solides et une approche analytique poussée. Une base de données SQLite robuste a été conçue avec sept tables interconnectées, facilitant l'intégration et l'extraction des données. Un script Python a automatisé la création de la base et l'importation des données, assurant efficacité et exactitude.

La connexion entre SQLite et Power BI via ODBC a permis de créer un tableau de bord interactif, offrant une analyse quantitative des publications selon les troubles, sujets, pays d'origine des auteurs, et périodes historiques. L'analyse de 83 000 articles a révélé des tendances temporelles marquantes de 1990 à 2020, mettant en lumière l'augmentation des publications dans certains domaines et les disparités géographiques.

Les visualisations interactives ont permis d'identifier des axes de recherche émergents et d'orienter les stratégies de collaboration et de financement. La solution se présente comme un outil décisionnel précieux pour les institutions de recherche, facilitant l'exploration des tendances sans compétences techniques avancées. Elle offre une veille sur l'évolution des thématiques scientifiques et fournit des informations stratégiques pour orienter les choix de financement et les décisions politiques.

En conclusion, ce projet démontre comment l'intégration de technologies (SQLite, Python, Power BI) peut offrir une solution performante et adaptable. Les analyses révèlent des tendances significatives, comme l'augmentation des publications sur l'ADHD et l'autisme, et des disparités entre pays développés et en développement. L'outil guide les orientations futures de la recherche, facilite l'identification de collaborations potentielles, et optimise l'allocation des ressources, offrant une vision claire et dynamique du paysage scientifique.

Annexes

[Troubles cognitifs ou troubles du neuro-développement et situations de handicap | Situations de handicap](#)

[trouble-du-neurodeveloppement-.pdf](#)

[5.1.2 Construire l'équation - Recherche structurée de littérature - Guides at CHUV, Centre hospitalier universitaire vaudois](#)